INSTITUTO POLITECNICO NACIONAL

septiembre 2025. **U P I I T A**

GUÍA PARA PRÁCTICA #1 _BIS **TEORÍA DE LA INFORMACIÓN**

Robert Roa Karla Guadalupe

ENTROPÍA DEL IDIOMA

OBJETIVOS

- Aplicar un análisis generalizado a la estructura del lenguaje mediante herramientas de estadística y de probabilidad.
- Calcular y analizar las entropías de textos en idioma español y de otros lenguajes (inglés, francés, italiano, portugués, alemán, náhuatl, sueco y catalán).
- Introducir los principios de la teoría de la información en el análisis de fuentes.

INTRODUCCIÓN

El propósito de esta práctica es realizar un análisis estadístico y probabilístico del lenguaje para cuantificar su estructura y contenido de información. Utilizando los principios de la **Teoría de la Información**, se busca calcular la entropía de la novela **"Madame Bovary"** de Gustave Flaubert, analizando para ello el texto original en francés junto a sus traducciones al inglés y español. La entropía, en este contexto, representa la cantidad promedio de información o el nivel de incertidumbre inherente a cada uno de estos idiomas.

Para asegurar que el análisis se centre únicamente en las propiedades estructurales de los alfabetos, los tres textos son "depurados" previamente. Este proceso implica convertirlos íntegramente a minúsculas y eliminar cualquier signo de puntuación o acentuación, aislando así las secuencias de caracteres para una comparación estadística directa.

Se calcularán tres tipos de entropía:

1. **Entropía como fuente sin memoria (H(X)):** Mide la información promedio por símbolo, asumiendo que la aparición de cada carácter es un evento independiente.

2. **Entropía de Markov de 1er Orden (H(X|Xn−1)):** Considera la dependencia de un carácter con el que le precede, ofreciendo un modelo más realista del lenguaje.

3. **Entropía de Markov de 2º Orden (H(X|Xn−2)):** Aumenta la complejidad al considerar la dependencia de un carácter con los dos anteriores, acercándose aún más a la estructura real del idioma.

INSTITUTO POLITECNICO NACIONAL

septiembre 2025. **U P I I T A**

DESARROLLO

A continuación, se presentan los resultados obtenidos para cada idioma.

a) TAMAÑO EN BYTES DE CADA UNO DE LOS 3 ARCHIVOS FUENTE

ESPAÑOL: 134,077 bytes
INGLES: 123,276 bytes
FRANCES: 136,127 bytes

b) GRÁFICA DE BARRAS QUE MUESTRE LOS 10 CARACTERES CON MÁS APARICIÓN EN EL TEXTO

NOVELA EN ESPAÑOL (CON Ñ)

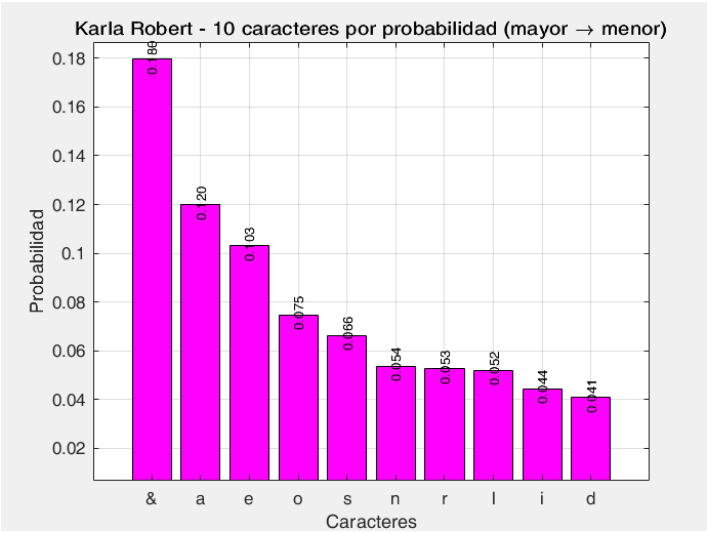

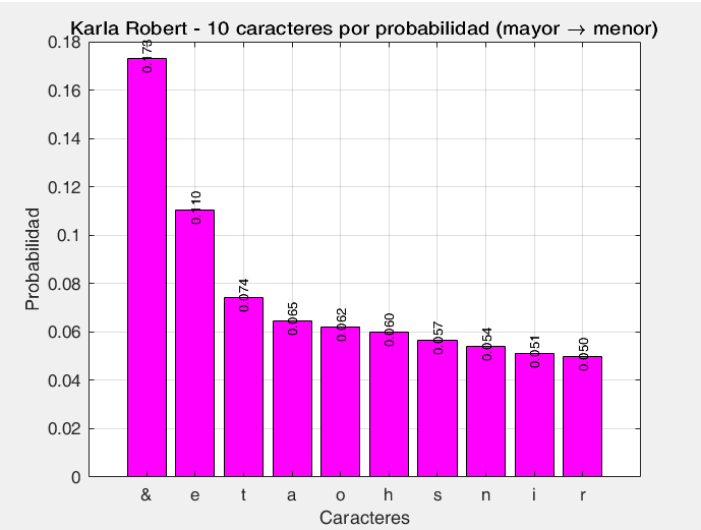

NOVELA EN INGLES

NOVELA EN FRANCES

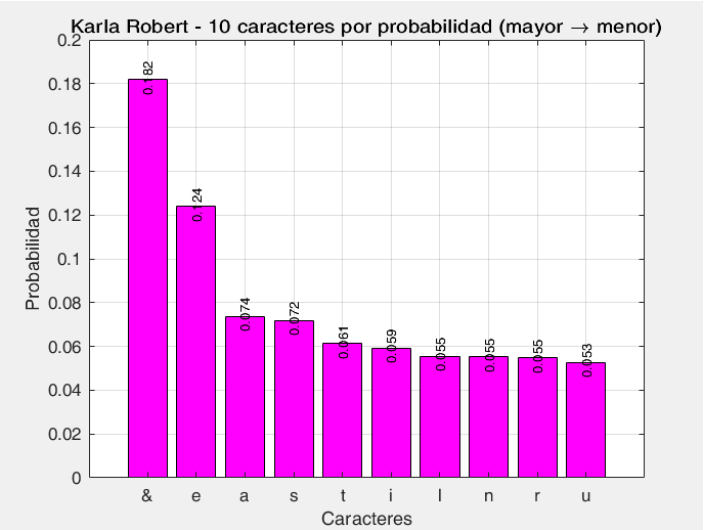

Estas gráficas de barras visualizan los 10 símbolos más comunes en cada idioma. Permite identificar la "huella digital" de cada lengua; por ejemplo, mientras que en español y francés las vocales 'a' y 'e' dominan después del espacio, en inglés la consonante 't' aparece en tercer lugar, demostrando una estructura de frecuencia distinta.

c) NÚMERO TOTAL DE CARACTERES POR CADA UNO DE LOS 3 TEXTOS DEPURADOS (3 IDIOMAS) INCLUIDO EL "ESPACIO".

IDIOMA	# DE CARACTERES
INGLES	123,276
ESPAÑOL	133,798
FRANCES	132,812

d) RELACIÓN ENTRE LETRAS VOCALES Y LETRAS CONSONANTES

IDIOMA	VOCALES	CONSONANTES	Tasa Vocal/Consonante
INGLES	38086	63865	0.596352
ESPAÑOL	50336	58962	0.853702
FRANCES	45613	60322	0.756159

Esta métrica compara la cantidad de vocales frente a las consonantes. Los resultados muestran que las lenguas analizadas son más "vocálicas" que el inglés, con el español presentando la tasa más alta (0.85), lo que influye directamente en la sonoridad y estructura silábica del idioma.

INSTITUTO POLITECNICO NACIONAL

septiembre 2025. **U P I I T A**

e) GRÁFICA DE PASTEL DE %VOCALES Y %CONSONANTES.

NOVELA EN ESPAÑOL (CON Ñ)

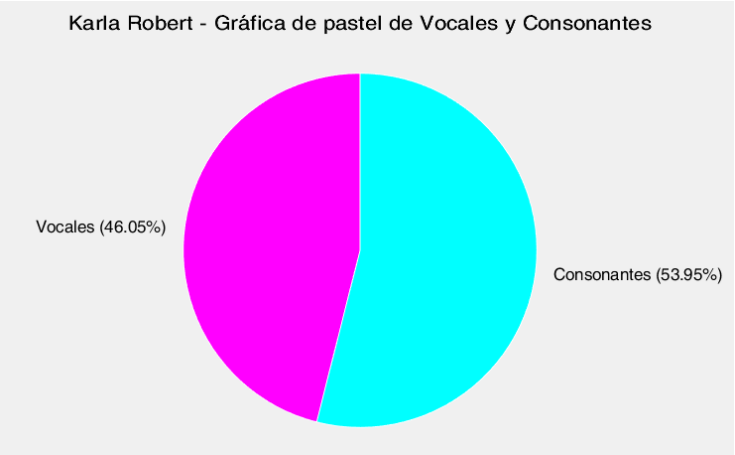

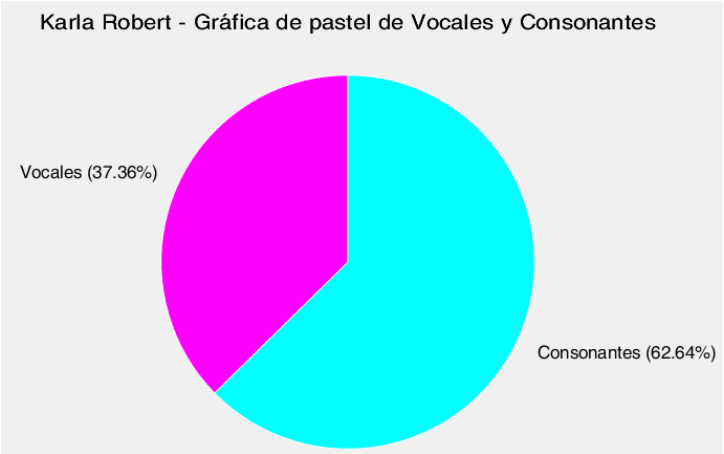

NOVELA EN INGLES

NOVELA EN FRANCES

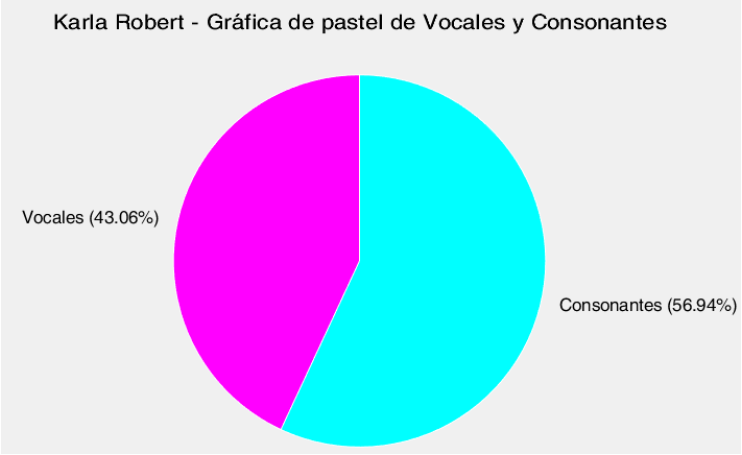

Nos permite visualizar la proporción porcentual entre vocales y consonantes. Se observa claramente que el inglés es el idioma con mayor predominancia de consonantes (62.64%), mientras que el español es el más equilibrado, con un 46.05% de vocales.

INSTITUTO POLITECNICO NACIONAL

septiembre 2025. **U P I I T A**

f) NÚMERO TOTAL DE PALABRAS.

IDIOMA	TOTAL DE PALABRAS
INGLES	21322
ESPAÑOL	23967
FRANCES	23055

g) NÚMERO PROMEDIO DE LETRAS POR PALABRA.

IDIOMA	Promedio Letras x Palabra
INGLES	4.78
ESPAÑOL	4.58
FRANCES	4.74

h) GRÁFICA DE BARRAS SÍMBOLO (XI) VS. P(XI). (P#0)

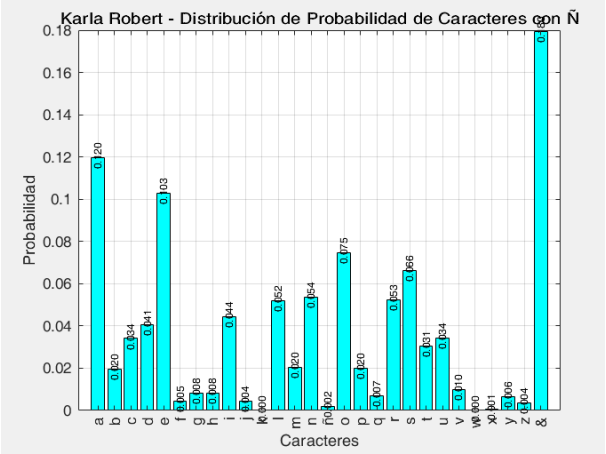

NOVELA EN ESPAÑOL (CON Ñ)

NOVELA EN INGLES

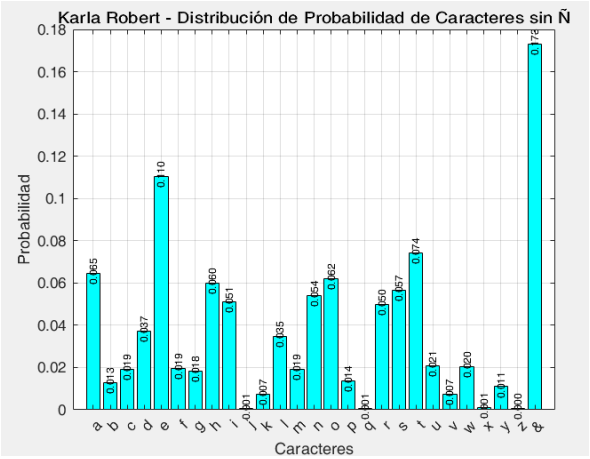

INSTITUTO POLITECNICO NACIONAL

septiembre 2025. **U P I I T A**

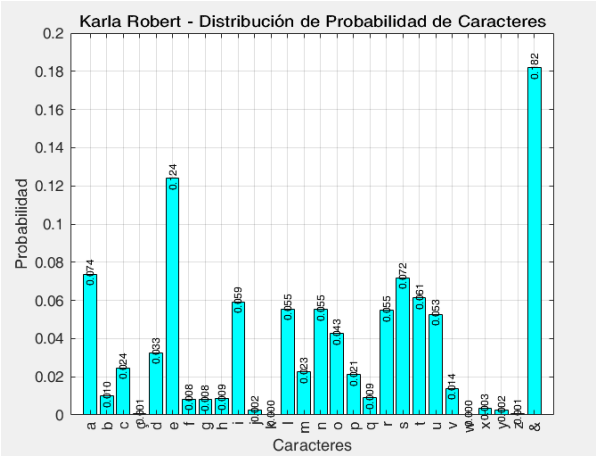

NOVELA EN FRANCES

Estas gráficas de barras ilustran la probabilidad de aparición de cada carácter del alfabeto. Confirma que en los tres idiomas el espacio es el carácter más probable, pero muestra diferencias clave en las letras subsecuentes (la 'e' en francés e inglés, y la 'a' en español), destacando las particularidades estadísticas de cada lengua.

i) GRÁFICA DE BARRAS SÍMBOLO (XI) VS. I(XI). (P#0)

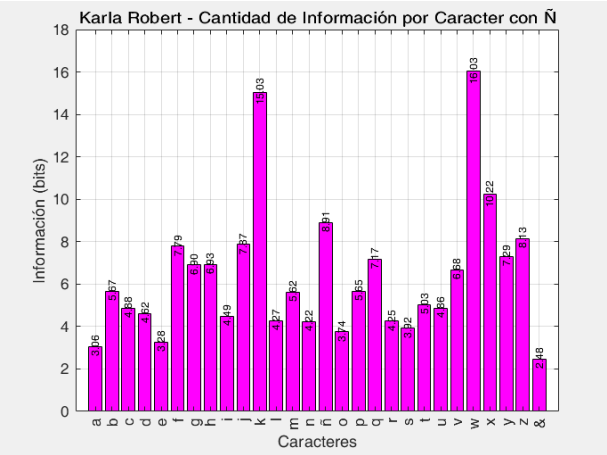

NOVELA EN ESPAÑOL (CON Ñ)

NOVELA EN INGLES

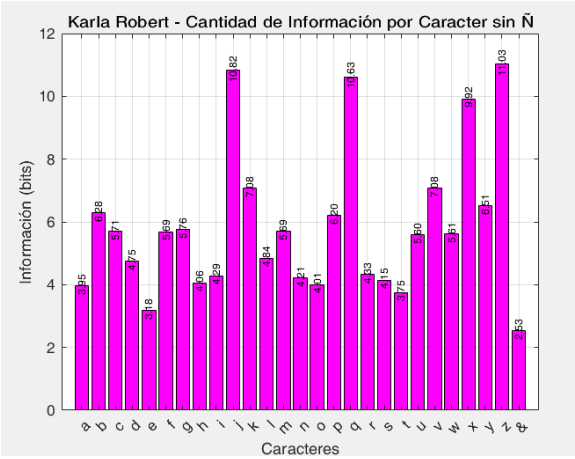

INSTITUTO POLITECNICO NACIONAL

septiembre 2025. **U P I I T A**

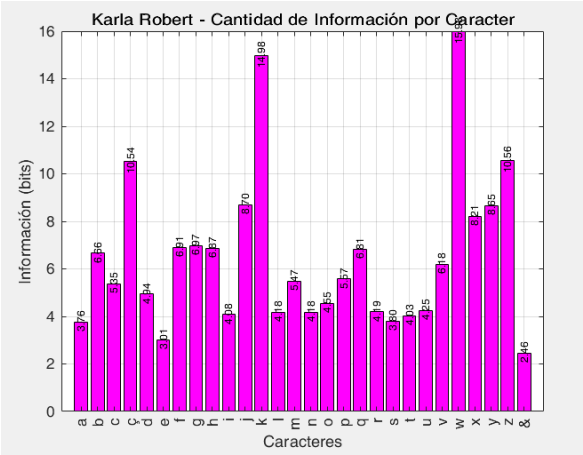

NOVELA EN FRANCES

Representan la información que aporta cada símbolo, donde los caracteres menos frecuentes (como 'k', 'w', 'x') contienen la mayor cantidad de bits. Los caracteres comunes como el espacio o la 'e' aportan muy poca información, ya que su aparición es altamente predecible.

j) ESTADÍSTICA DE APARICIÓN DE LOS SÍMBOLOS POR PAREJAS (DOS CARACTERES SEGUIDOS), Y POR TERCIAS (TRES CARACTERES CONSECUTIVOS).

NOVELA EN ESPAÑOL (CON Ñ)

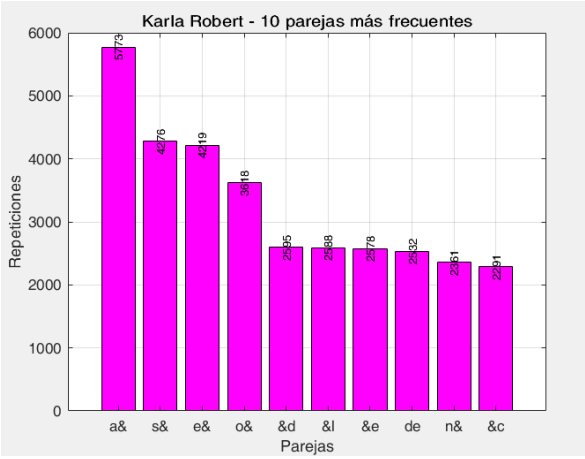

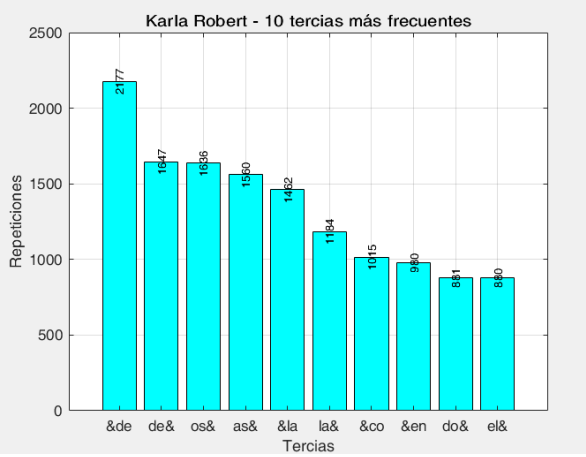

NOVELA EN INGLES

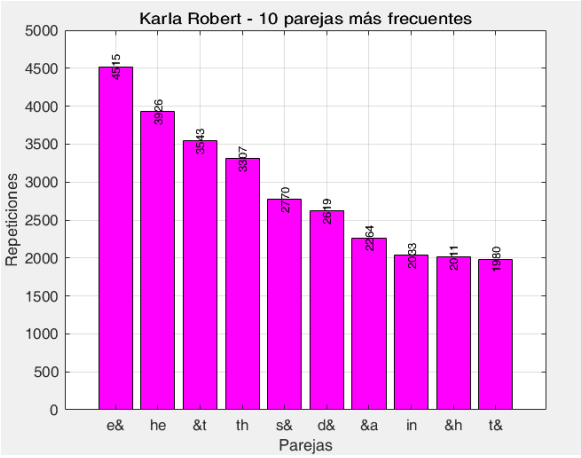

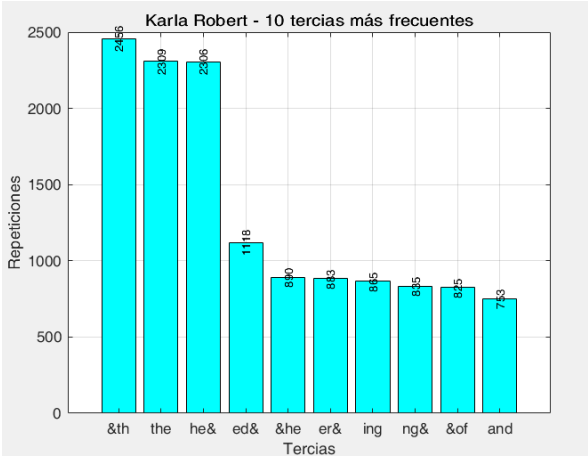

NOVELA EN FRANCES

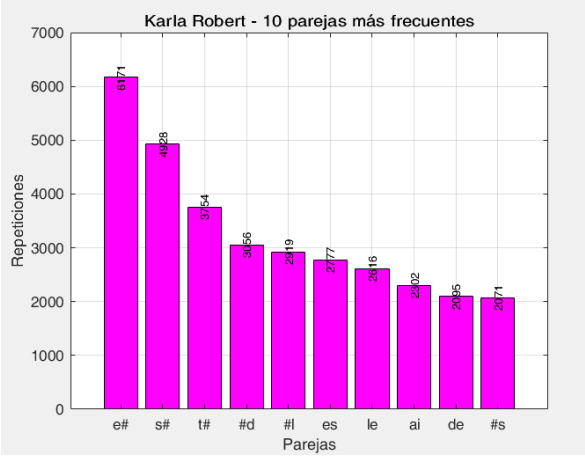

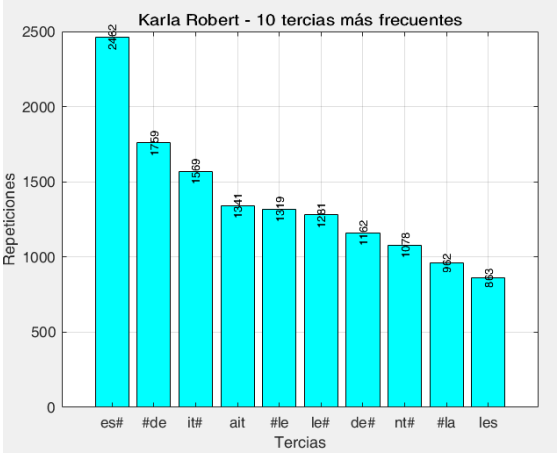

Estas gráficas muestran los conjuntos de letras más comunes de cada idioma. En inglés, por ejemplo, dominan las tercias &th y the, mientras que en español son &de y de&, (Donde el espacio se representa con el símbolo &). Este análisis introduce el concepto de memoria, mostrando cómo ciertos caracteres tienden a aparecer juntos.

k) CÁLCULO DE LA ENTROPÍA COMO FUENTE SIN MEMORIA. (P#0)

IDIOMA	ENTROPIA SIN MEMORIA
INGLES	**4.092490 bits/simbolo**
ESPAÑOL	**3.972734 bits/simbolo**
FRANCES	**3.968622 bits/simbolo**

Este cálculo mide la información promedio que aporta cada símbolo en el texto, asumiendo que la aparición de un carácter es totalmente independiente de los anteriores. Representa la incertidumbre base del idioma; es decir, cuántos bits se necesitarían en promedio para codificar cada símbolo si no existieran reglas ni patrones lingüísticos.

l) Cálculo de la entropía como fuente con memoria (Markov de 1° Orden)

IDIOMA	Markov de 1° Orden
INGLES	3.330362 bits/símbolo
ESPAÑOL	3.118033 bits/símbolo
FRANCES	3.073674 bits/símbolo

Este modelo es más realista, ya que calcula la información promedio de un símbolo dado que conocemos el carácter que le precede. Al introducir este contexto (memoria de un símbolo), la incertidumbre disminuye, ya que la estructura del idioma hace que ciertas secuencias de dos letras sean más probables que otras. Por esta razón, el valor de H1 siempre será menor que el de H0.

m) Cálculo de la entropía como fuente con memoria (Markov de 2° Orden)

IDIOMA	Markov de 2° Orden
INGLES	2.703237 bits/símbolo
ESPAÑOL	2.616784 bits/símbolo
FRANCES	2.404040 bits/símbolo

Este es el modelo más refinado de los tres. Mide la información promedio de un símbolo cuando ya conocemos los dos caracteres que le preceden. Al añadir más contexto, la incertidumbre se reduce aún más, ya que las secuencias de tres letras en un idioma son todavía más predecibles que las de dos. Por lo tanto, H2 siempre será el valor más bajo de los tres.

Conclusiones

El análisis estadístico de *Madame Bovary* en español, francés e inglés revela grandes diferencias entre los idiomas a través de la entropía. Los resultados, resumidos en la siguiente tabla, nos permiten conocer más acerca de la como se comporta cada lengua.

Tabla Comparativa de Resultados

Métrica Clave	Español	Francés	Inglés
Tasa Vocal/Consonante	0.8537	0.7561	0.5963
Entropía H_0 (Sin Memoria)	3.97273 bits	3.96862 bits	4.09249 bits
Entropía H_1 (Markov 1er Orden)	3.11803 bits	3.07367 bits	3.33036 bits
Entropía H_2 (Markov 2° Orden)	2.61678 bits	2.40404 bits	2.70323 bits

El análisis comparativo de las entropías nos muestra que cada idioma tiene una estructura única que define su predictibilidad. El inglés presenta la entropía más alta, posicionándose como el lenguaje con mayor incertidumbre o "sorpresa" por carácter, probablemente debido a su ortografía menos fonética y su mezcla de raíces lingüísticas. En comparación, el francés y el español, y en especial el francés, muestran la entropía más baja, lo que indica una estructura más predecible y regular gracias a sus reglas gramaticales y fonéticas. La caída de la entropía al incorporar memoria (modelos de Markov) en los tres idiomas, y de manera específica en el

francés, demuestra que, aunque la novela es la misma, el francés es el idioma más estructurado y el inglés el más rico en información por símbolo.

Tabla Comparativa de Entropías

IDIOMA	Comparación de Entropías
INGLES	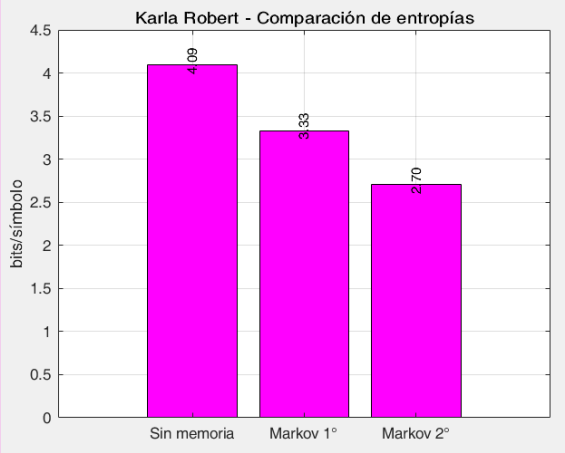
ESPAÑOL	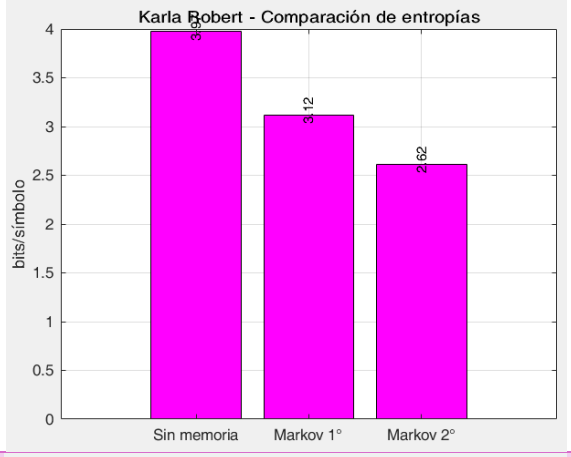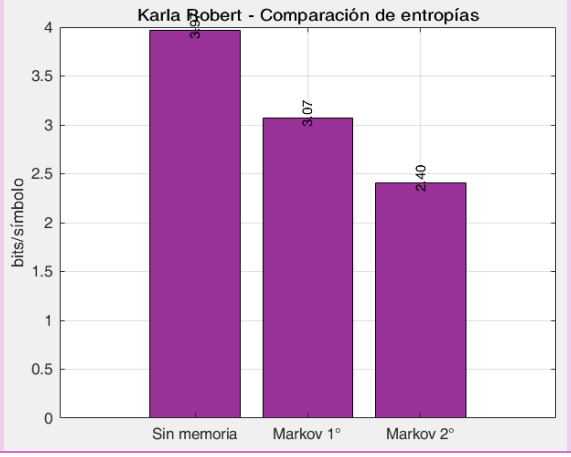
FRANCES